

Map Go

#map

#hashmap

#go

Простая реализация типа Map

Тип map по своей сути представляет таблицу из ключ значения. Посмотрим на простую реализацию:

```
type entry struct {
    key string
    value int
}

type simpleMap []entry

func lookUp(m simpleMap, key string) int {
    for _, e := range m {
        if e.key == key {
            return e.value
        }
    }
    return 0
}
```

А теперь посчитаем сложность: $O(n)$, что не соответствует стандарту hashMap

Идея: Деление на bucket

Разделим все наши данные на группы, назовем их бакетами. Каждый бакет будет содержать не более 8 элементов. Чтобы элементы в бакетах равномерно распределялись (не было ситуации, где все элементы начинаются с одного и того же символа), введем хэш функции.

Хэш функция

Хэш функция имеет следующий вид:

bucket = hash(key)

Данная функция должна отвечать следующим требованиям:

- Равномерность
- Быстрота
- Детерминированность
- Криптоустойчивость

Теперь мы имеем хэш таблицу.

Хэш таблицы

`v=m[k]` скомпилируется в: `v = runtime.lookup(m,k)`

Сигнатура `lookup`:

`func<K,V> lookup(m map[K]V, k K) V` - то есть у нас используются дженерики, т.к. значения в мапе могут быть универсальные. Но в go они появились в 1.19.

Но как обойтись без них?

- Все операции выполняются с помощью `unsafe.Pointers`.
- Мета-информация о типах хранится в **type descriptor**.
- Type descriptor предоставляет операции `hash`, `equal`, `copy`.

Например:

```
type _type struct {
    size uintptr
    equal func(unsafe.Pointer, unsafe.Pointer) bool
    hash  func(unsafe.Pointer, uintptr) uintptr
    ...
}
```

```
type mapType struct {
    key *_type
    value *_type
    ...
}
```

Теперь посмотрим исходный код Go

```
// A header for a Go map.
type hmap struct {
    // Note: the format of the hmap is also encoded in
    cmd/compile/internal/reflectdata/reflect.go.
    // Make sure this stays in sync with the compiler's definition.
    count      int // # live cells == size of map. Must be first (used
    by len() builtin)
    flags      uint8
    B          uint8 // log_2 of # of buckets (can hold up to loadFactor
    * 2^B items)
    noverflow  uint16 // approximate number of overflow buckets; see
    incrnoverflow for details
    hash0      uint32 // hash seed

    buckets    unsafe.Pointer // array of 2^B Buckets. may be nil if
    count==0.
    oldbuckets unsafe.Pointer // previous bucket array of half the size,
    non-nil only when growing
    nevacuate  uintptr // progress counter for evacuation
    (buckets less than this have been evacuated)

    extra *mapextra // optional fields
}
```

Теперь посмотрим во что же скомпилируется `v = m[k]`:

```
pk := unsafe.Pointer(&k)
func lookup(t *mapType,
            m *mapHeader,
            k unsafe.Pointer) unsafe.Pointer
pv := runtime.lookup(typeOf(m), m, pk)
v = *(*V)pv
```

Посмотрим список преобразований:

```
v := m["k"] → func mapaccess1(t *maptype,
                                h *hmap,
                                k unsafe.Pointer)
                                unsafe.Pointer

v, ok := m["k"] → func mapaccess2(t *maptype,
                                    h *hmap,
                                    k
                                    unsafe.Pointer) (unsafe.Pointer, bool)
```

```


m["k"] = 9001 → func mapassign(t *maptype,
                                h *hmap,
                                k unsafe.Pointer)

unsafe.Pointer

delete(m, "k") → func mapdelete(t *maptype,
                                h *hmap,
                                k
                                unsafe.Pointer)

```

Смотрим структуру



- Размер карты.
- Логарифм от кол-ва бакетов, для ускорения побитовых операций.
- Указатель на бакеты.
- Зерно.

LOB (Low Order Bits)

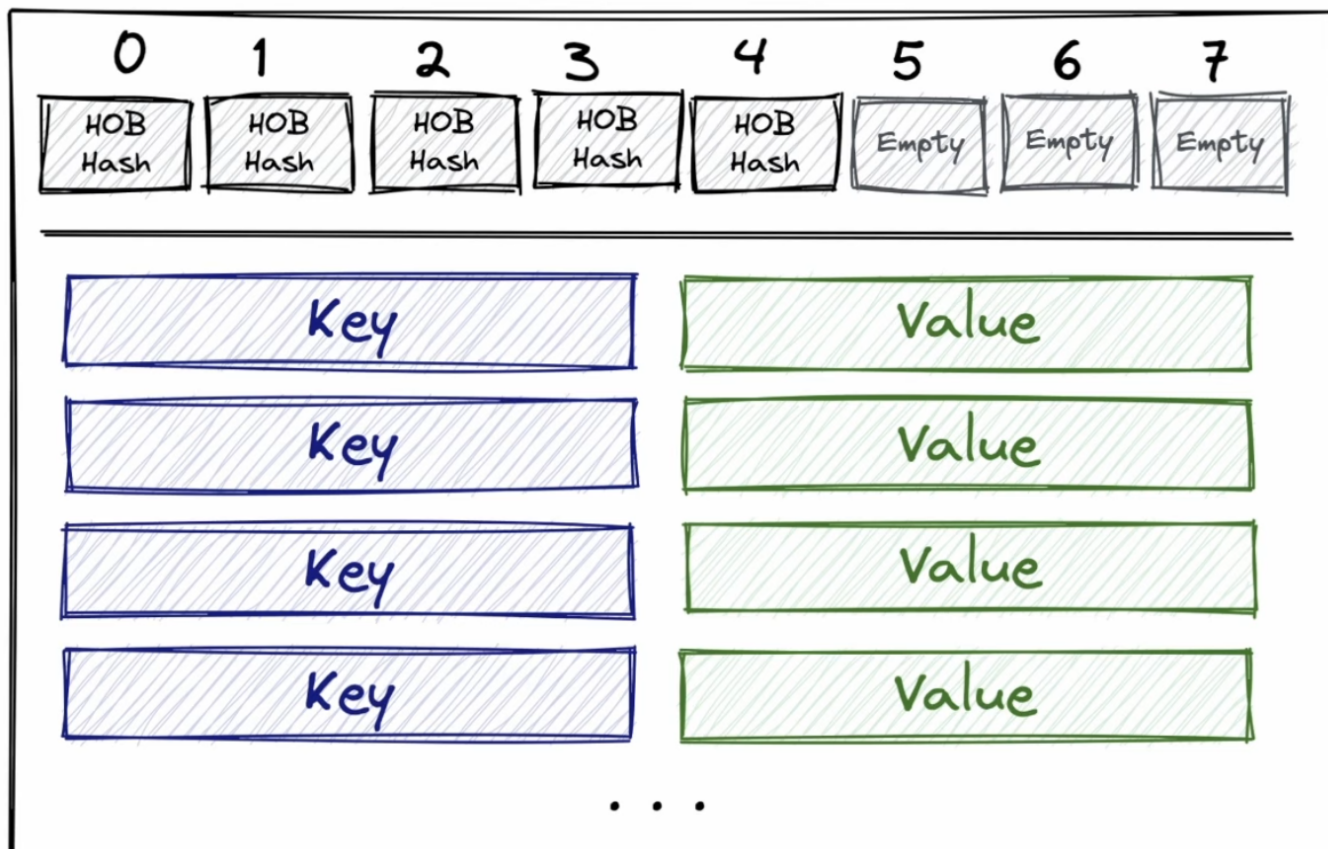
$Hash(key) = 5431$

Мы получили большое число, хотя бакетов мало. Как найти нужный?

Возьмем остаток от деления на кол-во бакетов: $5431 \% 4 = 1$. Однако остаток от деления считается побитово. Но там нам и нужен логарифм, т.к. в двоичном представлении \log последних бит будет соответствовать номеру нашего бакета.


Таким образом $LOB(Hash)=01$

Структура бакета



В каждом бакете хранится не более 8 значений.

В памяти это выглядит так:




Так как нам нужно выравнивать память для экономии места.

Также, во всех функциях используются побитовые маски, $1 \ll \log(n) - 1$ - универсальная операция для нахождения маски и при умножении любого числа на маску, получаем только последние n бит.

Переполнение бакета

Новая память выделяется тогда, когда в каждом бакеете лежит в среднем 6.5 значений. Как только бакееты достигают этого значения, начинается **эвакуация** бакеетов. Этот процесс достаточно медленный. Память также увеличивается в два раза.

Эвакуация данных из бакета



Именно поэтому мы не можем брать ссылку на элементы в мапе, т.к. они находятся в каком-то бакеете, а после эвакуации будут в другом, таким образом ссылка устареет.

Однако в `mapaccess1` возвращается указатель, но он всегда разыменовывается.

Почему обход случайный?

Обход итератора зависит слишком от многих факторов, старые бакееты, хэш функция и многое другое. Поэтому в итераторе был сделан `fastrand` чтоб обход был случайный. P.S. в пакете `fmt` идет сортировка элементов по ключам.